实验一报告：Linux内核编译及添加系统调用

陶莎 18271407

一、实验目的

Linux是开源操作系统，用户可以根据自身系统需要裁剪、修改内核，定制出功能更加合适、运行效率更高的系统，因此，编译Linux内核是进行内核开发的必要基本功。在系统中根据需要添加新的系统调用是修改内核的一种常用手段，通过本次实验，学生应理解Linux系统处理系统调用的流实验一报告：Linux内核编译及添加系统调用

二、实验内容

- （1）添加一个系统调用,实现对指定进程的nice值的修改或读取功能,并返回进程最新的 nice 值及优先级 prio。建议调用原型为:

  ```
  int mysetnice(pid_t pid, int flag, int nicevalue, void __user * prio, void __user * nice)
  ```

  参数含义：

  ```
  pid:进程 ID。
  nicevalue：为指定进程设置的新nice值。
  flag:若值为 0,表示读取 nice 值;若值为 1,表示修改 nice 值。
  prio、nice:进程当前优先级及 nice 值。返回值:系统调用成功时返回 0,失败时返回错误码 EFAULT
  ```

- (2)写一个简单的应用程序测试(1)中添加的系统调用。
- (3)若程序中调用了Linux的内核函数,要求深入阅读相关函数源码。

三、设计方案

这个系统调用需要对指定进程的nice值进行修改和读取，同时也要返回进程最新的nice值及优先级prio，分成以下功能：

- 根据进程索引pid找到对应的进程控制块PCB
- 根据PCB读取它的nice值和优先级prio
- 根据PCB对相应进程的nice值进行修改
- 将得到的nice值和优先级prio进程返回

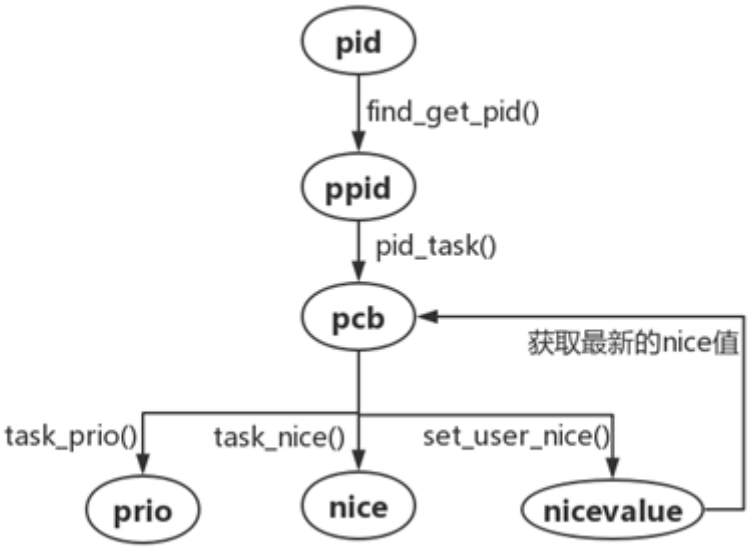

四、实验过程

- **添加系统调用号**

  `arch/x86/entry/syscalls/syscall_64.tbl`

系统调用号	应用二进制接口	系统调用名称	服务例程入口
333	64	mysetnice	sys_mysetnice

- **系统调用原型**

```
asmlinkage long sys_mysetnice(pid_t pid, int flag, int nicevalue, void
__user* prio, void __user* nice);
```

- **系统调用服务例程**

```
SYSCALL_DEFINE5(mysetnice, pid_t, pid, int, flag, int, nicevalue, void
__user*, prio, void __user*, nice)
{
    struct pid *ppid;
    //进程描述符指针，指向一个枚举类型
    struct task_struct *task;              //任务描述符信息
    ppid = find_get_pid(pid);               //通过索引pid_t返回pid
    task = pid_task(ppid, PIDTYPE_PID);     //通过pid返回进程task

    int curr_nice;
    curr_nice = task_nice(task);    //返回当前进程的nice值
    int curr_prio;
    curr_prio = task_prio(task);    //返回当前进程的prio值

    if(flag == 1){            //如果flag等于1修改进程的nice值
        set_user_nice(task, nicevalue);
        curr_nice = task_nice(task);       //重新获取修改过的nice值
        curr_prio = task_prio(task);       //重新获取修改过的prio值
    }
    else if(flag != 0){       //如果flag不等于1或者0返回错误码
```

```
        return EFAULT;
    }

    copy_to_user(nice, &curr_nice, sizeof(curr_nice));
    //将nice值拷贝到用户空间
    copy_to_user(prio, &curr_prio, sizeof(curr_prio));
    //将prio值拷贝到用户空间
    return 0;
}
```

- 编译内核

`make menuconfig`

`make`

`make modules`

`make modules_install`

`make install`

`update-grub2`

五、实验测试

- 用户态测试程序

```
#include <unistd.h>
#include <sys/syscall.h>
#include <stdio.h>

#define _SYS_TSSETNICE_ 333
#define EFAULT 14

int main()
{
    int pid, flag, nicevalue;
    int prev_prio, prev_nice, curr_prio, curr_nice;
    int result;

    printf("Hello, this is TS's syscall test...");
    printf("Please input variable like this: pid, flag(0/1), nicevalue");
    scanf("%d%d%d", &pid, &flag, &nicevalue);

    result = syscall(_SYS_TSSETNICE_, pid, 0, nicevalue, &prev_prio,
&prev_nice);

    if(result == EFAULT){
        printf("ERROR!\n");
        return 1;
    }
    else if(flag == 1){
        syscall(_SYS_TSSETNICE_, pid, 1, nicevalue, &prev_prio, &prev_nice);
        printf("Original priority is %d, Original nice is %d\n", prev_prio,
prev_nice);
        printf("Current priority is %d, Current nice is %d\n", curr_prio,
curr_nice);
    }
    else if(flag == 0){
```

```
        printf("Current priority is %d, Current nice is %d\n", curr_prio,
curr_nice);
    }
    else{
        printf("flag is not exist\n");
    }
    return 0;
}
```

- 查看当前终端的进程pid号，选择flag=0查看当前nice和prio值

```
iris@iris-virtual-machine:~$ ps
    PID TTY          TIME CMD
   3983 pts/1    00:00:00 bash
   4266 pts/1    00:00:00 ps
iris@iris-virtual-machine:~$ ./test
Hello, this is TS's syscall test...
Please input variable like this: pid, flag(0/1), nicevalue
3983 0 0
Current priority is 22, Current nice is 2
```

- 选择flag=1修改nice和prio值

```
iris@iris-virtual-machine:~$ ./test
Hello, this is TS's syscall test...
Please input variable like this: pid, flag(0/1), nicevalue
3983 1 3
Original priority is 22, Original nice is 2
Current priority is 23, Current nice is 3
```

六、问题记录和总结

- 编译完成后版本不变的问题
  - 检查grub.cfg文件，发现新的内核信息已经完全编译好并写入了，但是重启之后还是原来的版本，并没有被我新变异的内核替换
  - 原因：我编译的内核版本比下载的Ubuntu自带的内核版本低，所以还是启动的高版本内核，可以通过修改grub的配置选项， 将开机选择内核版本的菜单栏显示出来（默认是不显示，通过修改配置文件显示）

    ```
    //etc/default/grub

    #GRUB_HIDDEN_TIMEOUT  //此配置将影响grub菜单显示。若设置此选项为一个常数，则将在此时间内隐藏菜单而显示引导画面。菜单将会被隐藏，如果注释掉该行，则grub菜单能够显示，等待用户的选择，以决定进入哪个系统或内核。
    ```

- make -jn

  看实验书上有些在make后面加上-j可以加快编译速度，结果我加了之后总是编译失败会卡住然后黑屏，一直以为是我系统没装好的锅，重装了好几次虚拟机，后来查资料才发现后面还要加上n，以后遇到问题一定不能空想，白白浪费时间

- 看源码想刨根问底
  - 我会把用到的函数找出来看，然后不出意外里面还是嵌套了很多函数的，简直是无穷无尽，而且很多也想不懂最底层是怎么实现的，非常茫然
  - 但是其实后来查资料看到很多优秀的学习分享，大家也没有像我这样非要找出最底层的代码，其实了解这个函数由哪些功能构成应该就可以了，既然底层都写好了api了，那就直接用好了

附：相关源码

- 通过索引找到pid

```
struct pid *find_get_pid(pid_t nr)
{
    struct pid *pid;

    rcu_read_lock();                //RCU（同步机制）读过程开始
    pid = get_pid(find_vpid(nr));
    //通过find_vpid(nr) 来找到进程描述符(应该是遍历表找到)
    //然后通过get_pid来让count字段加1
    rcu_read_unlock();              //RCU读过程结束

    return pid;
}
```

- 通过pid找到task

```
struct task_struct *pid_task(struct pid *pid, enum pid_type type)
{
    struct task_struct *result = NULL;
    if (pid) {
        struct hlist_node *first;
        first = rcu_dereference_check(hlist_first_rcu(&pid->tasks[type]),
                          lockdep_tasklist_lock_is_held());
        if (first)
            result = hlist_entry(first, struct task_struct,
pids[(type)].node);
    }
    return result;
}
```

- 返回task的prio和nice
  - static_prio是静态优先级，不会随时间改变，内核不会主动修改，只能通过系统调用修改nice值去修改它，static_prio = MAX_RT_PRIO + nice +20, MAX_RT_PRIO的值为100，nice的范围为-20~19，值越小静态优先级越高；如果进程为非实时进程则prio = static_prio；若进程为非实时进程，则prio = MAX_TR_PRIO -1 - rt_priority，实施优先级越大进程优先级越高
  - realtime任务的调度优先级永远高于所有的非realtime任务，即非实时任务只有在没有任何实时任务运行时才可能被运行。
  - task_struct的prio成员取值范围是0~139，值越小，优先级越高，也就是prio为0的task具有最高优先级（idle task），而 task_prio函数返回的值，对应的范围是-100到39，可以看到减去了100

```
static inline int task_nice(const struct task_struct *p)
{
    return PRIO_TO_NICE((p)->static_prio);
    //从进程task_struct结构中获得静态优先级static_prio，然后通过PRIO_TO_NICE宏将其转化成nice值
}

int task_prio(const struct task_struct *p)
{
    return p->prio - MAX_RT_PRIO;
}
```

- 更改nice值

```
void set_user_nice(struct task_struct *p, long nice)
{
    bool queued, running;
    int old_prio, delta;
    struct rq_flags rf;
    struct rq *rq;

    //如果nice值的范围不在-20~19之间，直接退出
    if (task_nice(p) == nice || nice < MIN_NICE || nice > MAX_NICE)
        return;
    /*
     * We have to be careful, if called from sys_setpriority(),
     * the task might be in the middle of scheduling on another CPU.
     */
    rq = task_rq_lock(p, &rf);
    update_rq_clock(rq);

    /*
     * The RT priorities are set via sched_setscheduler(), but we still
     * allow the 'normal' nice value to be set - but as expected
     * it wont have any effect on scheduling until the task is
     * SCHED_DEADLINE, SCHED_FIFO or SCHED_RR:
     */
    //针对实时进程设置nice值，将nice值转成优先级后设置到p->static_prio
    if (task_has_dl_policy(p) || task_has_rt_policy(p)) {
        p->static_prio = NICE_TO_PRIO(nice);
        goto out_unlock;
    }
    queued = task_on_rq_queued(p);
    running = task_current(rq, p);
    if (queued)
        dequeue_task(rq, p, DEQUEUE_SAVE | DEQUEUE_NOCLOCK);
    if (running)
        put_prev_task(rq, p);

    //将nice值转成优先级设置到static_prio 中
    p->static_prio = NICE_TO_PRIO(nice);
    set_load_weight(p);
    old_prio = p->prio;
    p->prio = effective_prio(p);
    delta = p->prio - old_prio;
```

```
    if (queued) {
        enqueue_task(rq, p, ENQUEUE_RESTORE | ENQUEUE_NOCLOCK);
        /*
         * If the task increased its priority or is running and
         * lowered its priority, then reschedule its CPU:
         */
        if (delta < 0 || (delta > 0 && task_running(rq, p)))
            resched_curr(rq);
    }
    if (running)
        set_curr_task(rq, p);
out_unlock:
    task_rq_unlock(rq, p, &rf);
}
```

- 将内核态传递给用户态

```
static inline int copy_to_user(void __user volatile *to, const void *from,
                   unsigned long n)
//*to是内核空间的指针，*from是用户空间指针，n表示从用户空间想内核空间拷贝数据的字节数
{
    __chk_user_ptr(to, n);
    volatile_memcpy(to, from, n);
    return 0;
}
```